Proyecto 4 Bioseñales

Sherlyn Andrea Guzmán Graciano[1]

[1] UNIVERSIDAD DE ANTIOQUIA FACULTAD DE INGENIERÍA, BIOINGENIERÍA - Bioseñales

Keywords— **IA,Machine laerning, EEG, Alzheimer, patología, Deep learning, redes neuronales, entrenamiento.**

I. Introducción

En investigaciones previas, se llevó a cabo un exhaustivo análisis de señales EEG provenientes de dos grupos distintos: individuos con Alzheimer y un grupo control sin esta condición. Se aplicaron filtros específicos, como pasa altas y pasa bajas, así como un filtro wavelet, para mejorar la calidad de las señales. La cuantificación de la potencia espectral relativa en diversas bandas de frecuencia reveló que no existían diferencias estadísticamente significativas entre los grupos en las ocho regiones cerebrales analizadas.

Este trabajo representa la continuación de la investigación, centrándose en la aplicación de técnicas de aprendizaje automático, específicamente en el diseño y entrenamiento de una red neuronal. La finalidad es obtener una estructura óptima que permita evaluar de manera más precisa las posibles diferencias en la actividad cerebral entre los grupos estudiados. La red neuronal se entrenará utilizando los datos previamente procesados, buscando identificar patrones sutiles que podrían no haber sido detectados mediante métodos estadísticos convencionales. Este enfoque proporcionará una comprensión más profunda de la complejidad de las señales EEG y permitirá explorar posibles correlaciones no evidentes en el análisis estadístico previo.

II. Marco teórico

A. Machine learning

Realizar un resumen sobre una aplicación actual del machine learning en Bioingeniería.

El machine learning es un subcampo de la inteligencia artificial, que se define en términos generales como la capacidad de una máquina para imitar el comportamiento humano inteligente. Los sistemas de inteligencia artificial se utilizan para realizar tareas complejas de una manera similar a cómo los humanos resuelven problemas[1]. Es una forma de utilizar la IA. Fue definido en la década de 1950 por el pionero de la IA Arthur Samuel como “el campo de estudio que da a las computadoras la capacidad de aprender sin ser programadas explícitamente”.

La función de un sistema de aprendizaje automático puede ser descriptiva , es decir, el sistema utiliza los datos para explicar lo sucedido; predictivo , lo que significa que el sistema utiliza los datos para predecir lo que sucederá; o prescriptivo , lo que significa que el sistema utilizará los datos para hacer sugerencias sobre qué medidas tomar.

Hay tres subcategorías de aprendizaje automático:

1

Los modelos de aprendizaje automático supervisados,se entrenan con conjuntos de datos etiquetados, lo que permite que los modelos aprendan y se vuelvan más precisos con el tiempo.

2

En el aprendizaje automático no supervisado , un programa busca patrones en datos sin etiquetar. El aprendizaje automático no supervisado puede encontrar patrones o tendencias que las personas no buscan explícitamente.

3

El aprendizaje automático de refuerzo entrena a las máquinas mediante prueba y error para que tomen la mejor acción mediante el establecimiento de un sistema de recompensa.[1]

El machine learning, es utilizado en diversas áreas y aplicaciones,incluida la bioingenieria. Éste juega un papel crucial en bioingeniería por varias razones, ya que aporta herramientas y enfoques poderosos para analizar datos complejos en biología y medicina, por ejemplo. A continuación se muestra una aplicación en el contexto de ésta ingenieria:

A1 Metodología Robusta Basada en los Fundamentos del Machine Learning Para la Clasificación de Señales Biomédicas.

Contexto del Estudio:

La clasificación no supervisada de señales médicas o secuencias biológicas es uno de los problemas de la bioingeniería moderna que no está resuelto de una forma general y extrapolable. En este estudio se propuso una metodología robusta para tratar al detalle los fundamentos matemáticos para representar estas señales en espacios prehilbertianos mediante transformadas espaciales, y utilizamos técnicas basadas en los fundamentos del machine learning y la teoría de la señal para clasificarlas.

Para ilustrar la capacidad del método, se aplicaron a tres desafíos: La capacidad de hacer un seguimiento a nivel neuronal de señales cerebrales, se evalúo también la exactitud para clasificar proteínas de acuerdo a su función,y finalmente la clasificación de señales sintéticas de flúter auricular en un espacio muy reducido[2]:

El estudio se desarrolló de la siguiente forma:

Adquisición de Señales Neuronales: Se utilizaron 64 electrodos flexibles en el neocórtex de un ratón para registrar señales neuronales en 17 sesiones. El software JRCLUSTA facilitó la detección de activaciones neuronales.
Representación en Espacios Vectoriales:
Se introdujo la notación ã para representar distribuciones en espacios prehilbertianos. La representación de señales neuronales se realizó mediante la concatenación de ondas en distintos canales, formando vectores en ã.
Proyección de Señales:

Se implementó un algoritmo eficiente basado en la descomposición de valores singulares (SVD) y análisis de componentes principales (PCA) para reducir la dimensionalidad de las señales. El subespacio resultante permitió la proyección de vectores originales en un espacio prehilbertiano de menor dimensionalidad.
Desafíos Específicos:
Seguimiento de Activaciones Neuronales:
Se evaluó la capacidad del modelo para seguir la actividad neuronal en diferentes sesiones, identificando pérdidas y cambios en la actividad.
Clasificación de Proteínas:
Se utilizaron secuencias de proteínas de SwissProt y anotaciones de GOA para clasificarlas según su función. La reducción de dimensionalidad facilitó la identificación de familias de proteínas.
Diagnóstico de Flúter Auricular (FLA):
Se dispuso de 8,000 bucles de vectorcardiogramas para clasificar las simulaciones de FLA según dirección y velocidad. Resultados:
Seguimiento de Activaciones Neuronales:
El modelo alcanzó una precisión superior al 99% en la identificación de neuronas, permitiendo el seguimiento temporal y la detección de cambios en la actividad.
Clasificación de Proteínas:
La metodología logró una alta precisión en la identificación de familias de proteínas según su función.
Diagnóstico de FLA:

Se propuso una métrica C para clasificar simulaciones de FLA, superando asunciones fisiológicas no demostradas.

Este estudio demuestra el potencial transformador de las redes neuronales en bioingeniería, ofreciendo soluciones robustas y precisas para desafíos médicos complejos. La metodología propuesta tiene aplicaciones inmediatas en el desarrollo de dispositivos cerebrales, la investigación farmacéutica y el diagnóstico cardíaco, destacando la importancia de la intersección entre machine learning y bioingeniería.[2]

A continuación se expliquen diferentes conceptos que son también de gran importancia para el trabajo con machine learning en diferentes entornos.

B. Algoritmo Kmeans

El objetivo de K-Means es agrupar observaciones similares para descubrir patrones que a simple vista se desconocen. Para conseguirlo, el algoritmo busca un número fijo (k) de clústers en el dataset. [3]

Este número k es un hiperparámetro del algoritmo. Representa el número de centroides (centro del clúster) que queremos encontrar en el dataset.

1. Elección del número de clústers k. El primer paso siempre es elegir en cuantas agrupaciones queremos segmentar los datos.

2. Inicializar las coordenadas de los centroides. Los centroides se inicializan en coordenadas aleatorias. Suponiendo que tenemos k=2, iniciamos dos centroides, uno rojo y otro verde, en puntos aleatorios de los datos.

3. Asignamos cada punto a un clúster. Se calcula la distancia de cada punto a cada centroide, y se agrupa con aquel centroide más próximo.

4. Se recalculan los centroides de los clústers. Una vez tenemos todos los puntos asignados a un clúster, se recalculan los centroides de manera que vuelven a ser los centros de cada clúster.

Finalmente se repiten los pasos 3 y 4 hasta que se llega al criterio de parada. El proceso de asignar cada punto a un clúster y calcular los centros se repite hasta que se cumple el criterio de parada estipulado.[3]

C. Máquinas de vectores de soporte (SVM)

Las máquinas de vectores de soporte (SVM) son un tipo de algoritmo de aprendizaje supervisado que se puede utilizar para tareas de clasificación o regresión. La idea principal detrás de las SVM es encontrar un hiperplano que separe al máximo las diferentes clases en los datos de entrenamiento. Esto se hace encontrando el hiperplano que tiene el margen más grande, que se define como la distancia entre el hiperplano y los puntos de datos más cercanos de cada clase. Una vez que se determina el hiperplano, se pueden clasificar nuevos datos determinando en qué lado del hiperplano se encuentran. Las SVM son particularmente útiles cuando los datos tienen muchas características y/o cuando hay un margen claro de separación en los datos.[4]

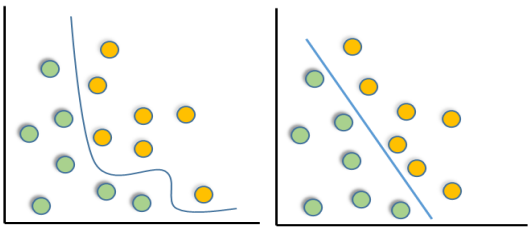

Fig. 1: Ejemplo de maquina de vector de soporte

D. Extreme gradient boosting

XGBoost, abreviatura de Extreme Gradient Boosting, se destaca como una biblioteca líder en aprendizaje automático para problemas de regresión, clasificación y ranking. Su nombre refleja su capacidad para mejorar árboles de decisión de manera extrema, proporcionando una solución escalable y distribuida basada en gradientes.[5]

En el aprendizaje automático supervisado, XGBoost se suma a la tarea de encontrar patrones en conjuntos de datos etiquetados. Utiliza árboles de decisión, algoritmos que evalúan características mediante preguntas de tipo sí/no para predecir etiquetas. A diferencia del método de bosque aleatorio, XGBoost se basa en el impulso de gradiente. Este enfoque iterativo ajusta árboles poco profundos en cada paso, utilizando los residuos de errores previos para mejorar la precisión del modelo. Además, XGBoost supera las limitaciones de velocidad computacional mediante la construcción paralela de árboles, optimizando el rendimiento del modelo.[5]

En resumen, XGBoost destaca por su capacidad para mejorar de manera extrema la precisión de los árboles de decisión, utilizando el impulso de gradiente para construir modelos iterativos de manera eficiente y escalable. Su aplicación abarca desde la clasificación hasta la regresión, convirtiéndolo en una herramienta esencial en el ámbito del aprendizaje automático.

E. Tamaño de efecto

E1 ¿ Qué es?

El tamaño del efecto es una medida de la magnitud de una diferencia entre dos grupos. En el contexto del machine learning se refiere a la magnitud o importancia práctica de las diferencias o relaciones identificadas por un modelo. El tamaño del efecto se puede utilizar para evaluar la importancia de las características de entrada en el modelo. Por ejemplo, si está construyendo un modelo de regresión lineal para predecir el precio de una casa, puede usar el tamaño del efecto para determinar qué características de entrada son las más importantes para predecir el precio de la casa. Además, el tamaño del efecto se puede utilizar para comparar diferentes modelos de aprendizaje automático y determinar cuál es el mejor para un problema dado [6]

E2 ¿Cómo se mide?

Hay tres formas comunes de medir el tamaño del efecto: la diferencia de medias estandarizada, el coeficiente de correlación de Pearson y el coeficiente de determinación.

La diferencia de medias estandarizada es una medida de la magnitud de la diferencia entre dos grupos. Se calcula dividiendo la diferencia entre las medias de los dos grupos por la desviación estándar de la población. Un valor de d de 0.2 se considera pequeño, 0.5 moderado y 0.8 grande.

El coeficiente de correlación de Pearson mide la fuerza de la relación lineal entre dos variables. Varía entre -1 y 1, donde -1 indica una correlación negativa perfecta, 0 indica que no hay correlación y 1 indica una correlación positiva perfecta. Un valor de 0.1 se considera pequeño, 0.3 moderado y 0.5 grande.

El coeficiente de determinación mide la proporción de la varianza en la variable dependiente que se puede explicar por la variable independiente. Varía entre 0 y 1, donde 0 indica que la variable independiente no explica la varianza en la variable dependiente y 1 indica que la variable independiente explica toda la varianza en la variable dependiente. Un valor de 0.02 se considera pequeño, 0.13 moderado y 0.26 grande.

Es importante tener en cuenta que el tamaño del efecto no es una medida de la significación estadística. En cambio, se utiliza para evaluar la importancia práctica de los resultados[6]

F. Correlación

La correlación es una medida estadística que describe la relación entre dos variables. En el contexto de problemas de machine learning, la correlación se utiliza a menudo para seleccionar características (o atributos) que tienen una fuerte relación con la variable objetivo que se está tratando de predecir.[7]
Para evaluar la correlación entre dos grupos de datos, es necesario seguir diferentes pasos con lo son el calculo de la correlación como tal y su visualización mediante una matríz.

Una matriz de correlación es una tabla que muestra las correlaciones entre varias variables en un conjunto de datos. luego de calcular la matriz de correlación entre todas las características del conjunto de datos, se visualiza esta matriz para identificar patrones de correlación y establecer un umbral. Luego, se eliminan características altamente correlacionadas entre sí para evitar multicolinealidad. Finalmente, se evalúa la correlación entre cada característica y la variable objetivo, conservando aquellas con correlaciones significativas. Estos pasos ayudan a seleccionar características relevantes para el modelo, aunque se debe tener en cuenta que la correlación no implica causalidad, y la selección de características debe ser parte de un proceso más completo de exploración y evaluación del conjunto de datos.[8]

G. ¿ cúales características podrían tener mayor potencial para construir un sistema de clasificación entre las diferentes clases?

Para construir un sistema de clasificación que pueda distinguir entre diferentes clases teniendo en cuenta consultas sobre tamaño de efecto y correlación, es esencial considerar características que exhiban variación significativa entre las clases y que estén correlacionadas de manera única con la pertenencia a cada clase, cómo por ejemplo características que muestren diferencias sustanciales en su distribución entre las clases son cruciales.

También distinguir entre variables donde el tamaño de efecto, sea estadísticamente significativo. Esto asegura que las características elegidas realmente contribuyan a la separación entre clases.

Identificar características que estén altamente correlacionadas con la variable de clase también es algo necesario, ya que características que posean alta correlación positiva o negativa son valiosas para el proceso de clasificación.

Finalmente la información mutua entre las variables, ya que ésta es una medida de la dependencia entre dos variables y se pueden utilizar métodos de selección de características basados en información mutua para identificar aquellas que aportan más información para distinguir entre clases.[9]

III. Descripción de trabajo anterior

A. Procesamiento y acondicionamiento de la señal

A partir de un set de archivos de 44 datos , se dispone de señales de EEG que fueron clasificadas en diferentes categoría, incluyendo sano (control) y con alzheimer (casos).

El objetivo del proyecto 3 fue determinar si era posible obtener información significativa a partir del procesamiento de estas señales y realizar un análisis estadístico de las mismas. El propósito principal consistió en identificar patrones o características distintivas en las señales procesadas que pudieran ser utilizadas para diferenciar y clasificar los diferentes tipos pacientes usando los parámetros del PSD relativo en un rango específico de frecuencias.

Estas señales contienen dentro de su estructura tanto ruido perteneciente a movimientos oculares,como otros posibles ruidos generados durante los procesos de captación de la señal y finalmente las propias señales de cerebrales de interés.Anteriormente ya tenían un filtrado de ruido realizado por las maquinas de recolección de datos.

Para ello entonces se procede a realizar un filtrado.El filtrado se realizó posterior a hacer gráficas que mostraran el promedio de PSD para todos lo canales y pacientes. De ésta de forma se puso observar entre qué rango de frecuencias se podía trabajar, además de esto se especificó que el rango de interés eran de 1 a 50hz, por lo que se diseñan los filtros para este rango. Sin embargo, se debe considerar que el ruido POR movimientos oculares se podía solapar con la frecuencia de la señales cerebrales , por lo que no se puede aplicar un filtro FIR como se haría en el primer caso. Es por esto que se requiere de un filtrado que discrimine también por amplitud tal como lo hace el filtro wavelet.

En primer lugar, se diseñan los filtros pasa altas y pasa bajas para las frecuencias de 1 Hz y 50 Hz respectivamente, en este caso se toma una ventana Hamming debido a que poseía valores de atenuación y desviación lo suficientemente bajos para ayudar a discriminar de forma adecuada las señales. Con respecto al orden, este fue calculado mediante la normalización de la frecuencia de Nyquist el cual es la frecuencia de muestreo, y utilizando la frecuencia de ancho de banda normalizada.

Inicialmente se obtuvieron filtros con los siguientes ordenes:

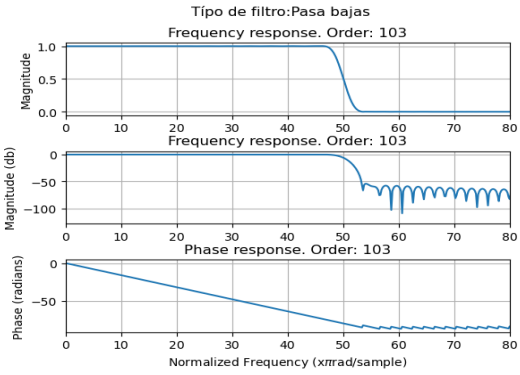

Fig. 2: Pasa bajas inicial

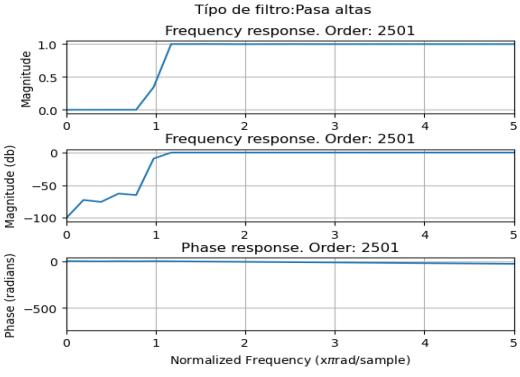

Fig. 3: Pasa altas inicial

B. *Procesamiento y extracción de características de la seña*

Prosiguiendo con el análisis, se llevó a cabo el mismo proceso para todos datos, discriminando entre los as señales oculares y cerebrales de amplitud menor, tal como se indica. Se identificaron diferentes rangos de frecuencia en los cuales parecen existir diferencias entre los distintos datos.

Se obtuvo el siguiente filtrado:

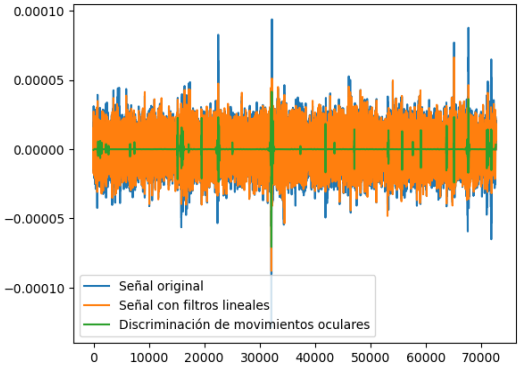

Fig. 4: Aplicación de los filtros FIR y Wavelett

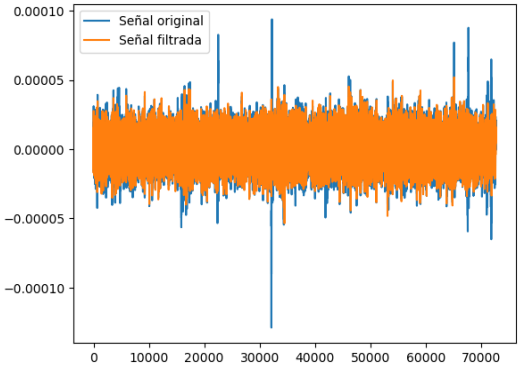

Fig. 5: Señal filtrada

A partir de esto, se crearon diferentes dataframes que discriminaban por ancho de banda el promedio del PSD relativo para los rango de 1 a 50 hz. Lo que nos deja con un set de datos sobre el cual se realizaran pruebas estadística con el fin de encontrar si hay diferencias significativas entre los grupos de sano, Los resultados que se obtuvieron fueron los siguientes:

Table 1: Resultados estadísticos

Canales	Set de pacientes e	bandas de frecuencia v	Resultado
1 a 8	Control vs Alzheimer	Beta	No hubo diferencia significativa entre los grupos
1 a 8	Control vs Alzheimer	Alpha	No hubo diferencia significativa entre los grupos
1 a 8	Control vs Alzheimer	Delta	No hubo diferencia significativa entre los grupos
1 a 8	Control vs Alzheimer	Theta	No hubo diferencia significativa entre los grupos
1 a 8	Control vs Alzheimer	Gamma	No hubo diferencia significativa entre los grupos

IV. Metodología

Antes de comenzar, se realizó una revisión exhaustiva entonces del trabajo 3 primero para poder corregir errores. Las recomendaciones hechas fueron mejorar el orden del filtro pasa altas para que no fuera tan alto, en lugar de hacer 5

dataframes, organizar todo en uno solo para que de esta forma fuera más fácil para la red neuronal trabajar y finalmente revisar el reshape de la señal al pasar a 5 épocas.

Se hizo entonces la mejora del filtro pasa altas, que fue el que mostró un orden bastante alto, por otra parte el pasabajas se mantuvo igual y estos fueron los resultados.

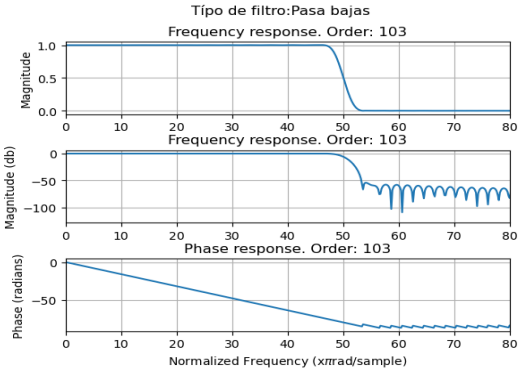

Fig. 6: Pasa bajas inicial

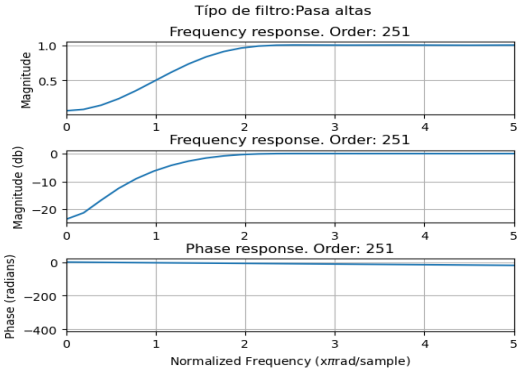

Fig. 7: Pasa altas inicial

Se observa entonces el cambio de la figura 9 con respecto al nuevo, donde su orden bajó a 250, mientras que el pasa altas se mantuvo. Se aplicó de nuevo el filtrado obteniendo las siguientes imágenes donde se observa que el cambio del filtro del orden no tuvo efectos significativos en el filtrado final.

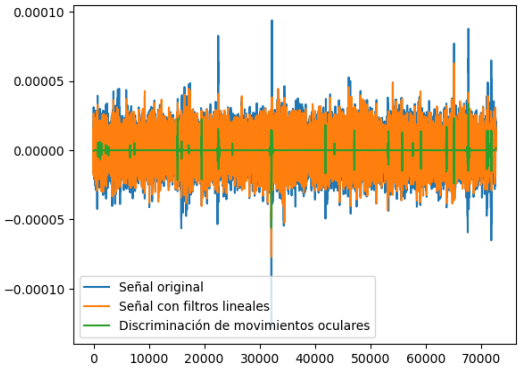

Fig. 8: Aplicación de los filtros FIR y Wavelett

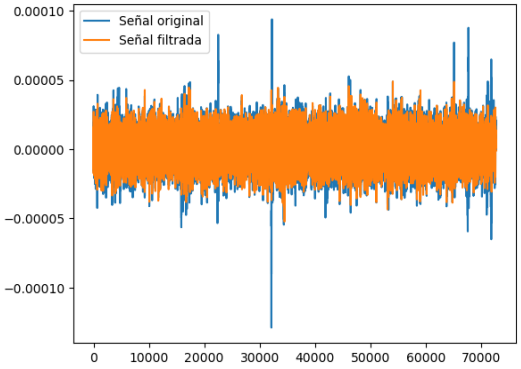

Fig. 9: Señal filtrada final

Se aplicó entonces este filtrado a todos los datos correspondientes, luego se realizó de nuevo un reshape, tomando el valor del módulo divido por 1000 y restando posteriormente al valor original, además de esto se realizó la corrección del dataframe.

Ahora, se prosigue a realizar, todo el trabajo consiguiente para la creación de las estructuras de redes neuronales:

Como a la hora de hacer el dataframes inicial no se promedió si no que se trabajo con el PSD relativo obtenido, aquí fue posible sacar un promedio, varianza y sumatorio para cada canal y banda de frecuencias.

Cabe destacar que cuando se refiere al promedio, se utilizó primero el promedio del PSD relativo, pero a la hora de la creación de la red neuronal, no dio muy buenos resultados, por lo que se optó por hacer lo siguiente:

Se optó por la creación de nuevas columnas.

Para el promedio de PSD relativo, Se toman todos los canales de cada rango, se promedian hasta obtener obtiene una columna correspondiente a la cual se la saca el promedio y se le resta a los valores anteriores. Esto para obtener valores

que correspondieran por ejemplo a pesos, por decirlo de alguna forma.

Para la varianza, Se crea la función de varianza y se calcula . Para la sumatorio se hace de forma similar. Obteniendo al final 15 columnas.

Se realizó también un encouder para convertir las variables cualitativas en cuantitativas, en este caso, los estados quedaron dela siguiente forma:

Table 2: Variables redefinidas

Pacientes	Estado
Alzheimer	0
Control	1

Posteriormente se hace entonces una matriz de correlación con los datos normalizados y observa la correlación para cada columna para así poder definir el tamaño de efecto tenemos, en este caso solo 4 columnas dieron un tamaño con un porcentaje positivo, entonces esas fueron las columnas que se eligieron.

A. *Creación de redes neuronales*

Posterior a esto se comienzan a generar las redes neuronales. Para la creación de las redes se siguieron los siguientes pasos:

Se escogieron primero entonces 4 funciones de activación, escogiendo una diferente para cada red, entonces en total se tendrían 4 redes. Esto se muestra en la tabla x. Se escogió en este caso una red con 20 neuronas en cada una de las capas que en total fueron 3. Se evaluaron entonces las siguientes métricas: Presición, recall y f1 -score.

La precisión mide la fracción de predicciones positivas que son correctas, mientras que el recall mide la fracción de ejemplos positivos que fueron correctamente identificados por el modelo. El F1-score es una medida de la precisión y el recall, y se utiliza para proporcionar un equilibrio entre ambas métricas. Es la media armónica de la precisión y el recall, y se utiliza comúnmente cuando se desea evaluar el rendimiento general de un clasificador.

Luego de ésto se escoge la mejor red basada en la función de activación que dio mejores valores de accuracy y mejor matriz de confusión.

Posterior a eso se realiza una rutina que varia los valores de neuronas aplicados en cada capa, se eligen valores que irán desde 1 a 45, es decir, habrá combinaciones de tuplas de la siguiente forma : (1,1,1), (2,2,2), (3,3,3), y así sucesivamente. Se escogerá la mejor de éstas y con respecto a esa se mostrará nuevamente la matríz de confusión y el mapa que mostrará el valor de accuracy y las méetricas.

Luego se realiza una segunda variación, donde esa red con la mejor tupla se varia también por el número de neuronas por capa, sumando 5 valores, es decir, (37,35,35), 0 (35,36,37), y así hasta un tope máximo para cada capa que serán de 40 neuronas,en éste caso se escoge también la mejor tupla . Se comparan todas las variaciones de redes y se escoge finalmente la que dió mejores valores de ajuste.

B. *Aplicaciones de rutinas*

Se aplicaron 3 rutinas.

B1 K means

El objetivo de K-Means es agrupar observaciones similares para descubrir patrones que a simple vista se desconocen. Para conseguirlo, el algoritmo busca un número fijo (k) de clústers en el dataset.

En este caso, se utiliza la técnica de clustering, un algoritmo de aprendizaje no supervisado. Los datos se separan y normalizan, y luego se entrena el algoritmo con el conjunto completo de datos de entrada. Se especifica la generación de 2 clusters, en función de la naturaleza de los tipos de pacientes, posteriormente se grafican adicionalmente en dos dimensiones para observar cómo se comportan los datos.

En cuanto a las métricas utilizadas, se considera la inercia, la puntuación de silueta y el índice Rand.

B2 Maquinas de soporte vectorial

De manera similar a los casos anteriores, en este contexto se utiliza la misma métrica y se evalúan los hiperparámetros utilizando la función GridSearchCV(). Sin embargo, se excluye el kernel de pre-compute debido a que requiere datos en formato cuadrado (nxn). Luego, se entrena el modelo con los mejores hiperparámetros y se realiza la predicción basada en este modelo.

Este proceso se lleva a cabo para los dos tipos de pacientes, siguiendo una selección y separación de datos similar a la utilizada en las redes neuronales.

B3 Extreme gradient boosting

Se aplica el gradient boodting, este algoritmo construye árboles de decisión de manera secuencial,corrigiendo los errores de los modelos anteriores. Se establece una cuadrícula de parámetros para probar diferentes combinaciones durante la búsqueda en cuadrícula. Estos parámetros son fundamentales para el rendimiento del modelo:

N estimators: Número de árboles en el ensamblado. Learning rate: Tasa de aprendizaje que controla la contribución de cada árbol. Max depth: Profundidad máxima de cada árbol.

De manera similar a la aplicación de matrices de soporte vectorial se sigue un proceso de selección y separación de datos para escoger el modelo con los mejores.

V. Resultados

A. Matríz de correlación

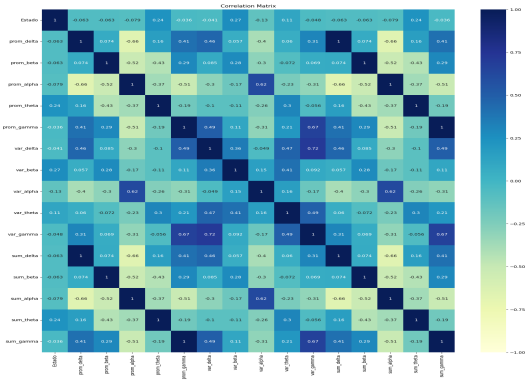

Fig. 10: Matriz de correlación

B. Curva de aprendizaje

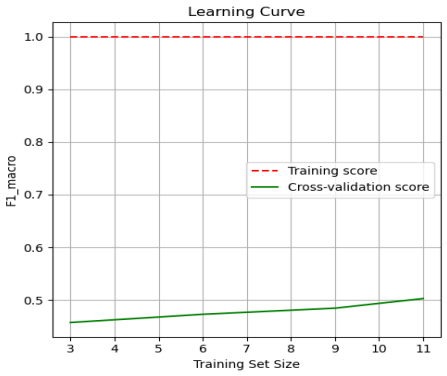

Fig. 11: Curva de aprendizaje

Para que el aprendizaje sea óptimo, se espera que la curva de cross validatión score de a se acerque lo máximo posible a la de entrenamiento, o en otras palabras, éstas deben converger, cómo se observa en la gráfica, la curva sí comienza a mostrar este tipo de comportamiento, aunque sería más fácil de visualizar si se tuvieran más datos para el entrenamiento.

C. Resultados redes neuronales

Usando una redes neuronal de 3 capas y distribuyendo 20 en cada una de éstas, se obtuvo que de las 4 funciones de activación la mejor fue identity. En la siguiente tabla se reportan los valores obtenidos para los datos de validación.

Table 3: Redes neuronales obtenidas

Red	Función de activación	Valor de accuracy (%)
1	Relu	62.0
2	Identity	68.7
3	tanh	56.2
4	Logistic	56.2

Como se puede observar en la tabla 3, el valor de accuracy que representa el porcentaje total de valores correctamente clasificados, tanto positivos como negativos, fue mayor para la red que se activó con la función identity. La matríz de confusión y mapa obtenidos para ésta fueron los siguientes.

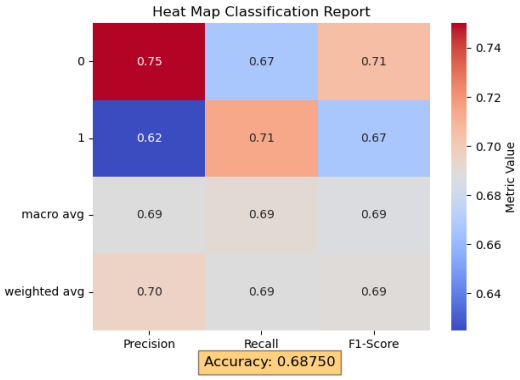

Fig. 12: Mapa de clasificación

Además de esto, se puede observar cúal fue el valor que obtuvo cada una de las métricas aplicadas, siendo 0 el valor mínimo que pueden alcanzar y 1 el valor máximo.

Para el estado cero, es decir pacientes con alzheimer ,se observa que se obtuvieron valores relativamente altos para cada una de las métricas, por ejemplo, se obtuvo una presición de 75 %, una recall del 67% y finalmente un f1-score del 71%.

Para el estado 1 que corresponde a los pacientes control, se obtuvo una presición de 62%, un recall del 71% y un f1-score del 67

Esto quiere decir que la red presentó una mejor fracción de predicciones positivas correctas con respecto a los pacientes alzheimer, sin embargo ésta fracción de predicciones también fue relativamente alta para los pacientes control. Con respecto al recall, el número de ejemplo positivos que fueron identificados correctamente fue mayor para los pacientes

control que alzheimer, pero manteniendo que para los dos grupos de datos, los rangos de porcentajes no son muy alejados.

Finalmente, el f-1 score fue mejor para los pacientes alzheimer, esto quiere decir que con respecto a este estado el equilibro entre las métricas de presición y recall es mejor.

Los porcentajes obtenidos para cada métrica fueron mayores al 62 % lo que quiere decir que el entrenamiento de la red fue positivo.

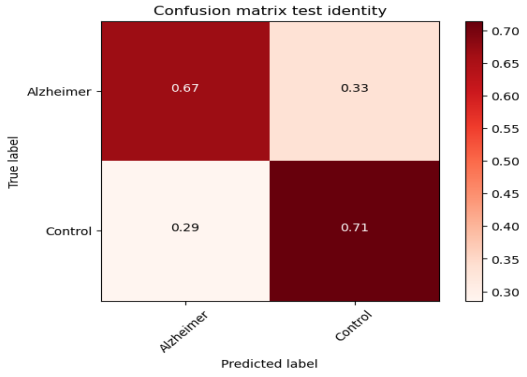

Fig. 13: Matríz de confusión

Ahora, al observar la matríz de confusión se evidencia que se valores positivos con respecto a la identifación de positivos y negativos en los datos.

Se obtuvo un valor de 67% con respecto a la identificación de verdaderos positivos y un valor de 0,71% para la identificación de verdaderos negativos, todo esto con respecto a los dos grupos, es decir, pudo identificar en su mayoría correctamente los datos que pertenecían a los pacientes Alzheimer y control, de forma parecida también identificó correctamente los datos que no pertenecían a cada grupo.

Los valores de falsos negativos y falsos positivos fueron de 29% y 33% respectivamente. Esto es algo positivo ya que es un indicador de que la red tuvo tiene más afinidad por identificar correctamente los valores que pertenecen a cada grupo de datos realmente.

C1 Segunda variación

Para la segunda variación, se obtuvo la mejor red con los siguientes valores : (35,35,35), es decir, una red de tres capas con 35 neuronas en cada una de ellas usando la función de activación identity.

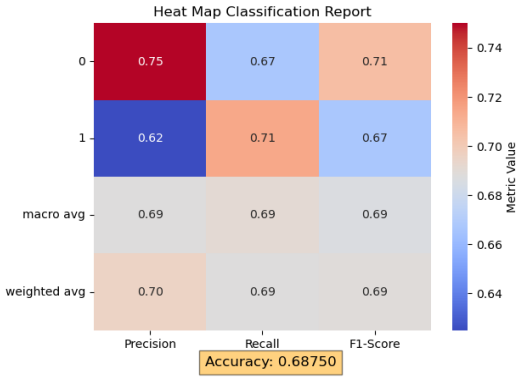

Fig. 14: Mapa de clasificación segunda variación

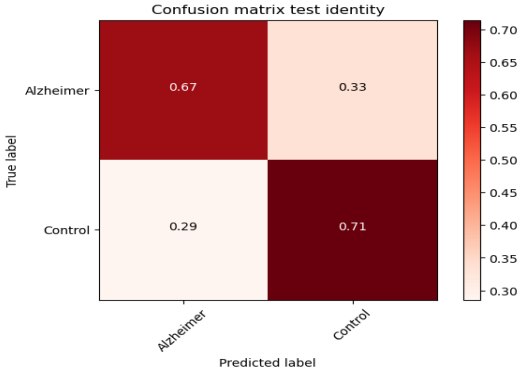

Fig. 15: Matríz de confusión segunda variación

C2 Tercera variación

Finalmente para la tercera, se obtuvo una red de activación don las neuronas distribuidas de la siguiente forma (33,40,33).

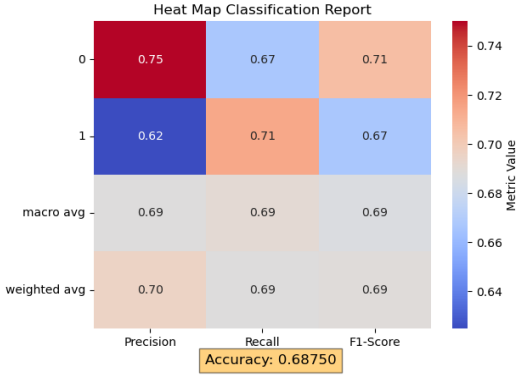

Fig. 16: Mapa de clasificación tercera variación

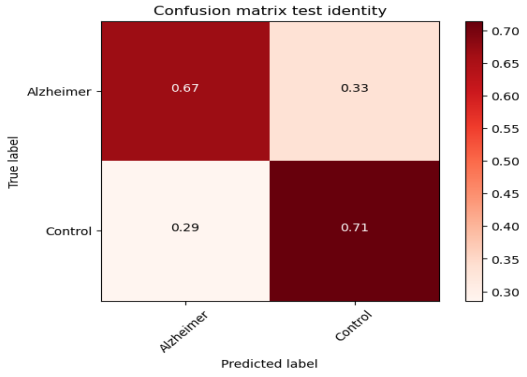

Fig. 17: Matríz de confusión tercera variación

Se observa entonces que el comportamiento de las redes al cambiar sus número de neuronas por capa no cambió significativamente, los valor de presición, recall y f1-score se mantuvieron exactamente igual. Para las matrices de confusión sucedió algo parecido, donde se mantuvieron los porcentajes de identificación correcta de positivos verdaderos y negativos verdaderos con respecto a los datos.

El que los valores sean muy similares entre las tres configuraciones de redes neuronales sugiere que, en este caso específico, el cambio en el número de neuronas por capa no tuvo un impacto significativo en el rendimiento del modelo.

Esto puede deberse a varias razones, como por ejemplo que problema abordado no sea lo suficientemente complejo como para que el aumento en el número de neuronas por capa tenga un impacto significativo en el rendimiento del modelo, esto debido a que cantidad de datos de entrenamiento no es lo suficientemente grande, la red puede no beneficiarse significativamente de un aumento en la complejidad.

Por otra parte, sí se presentaron algunos cambios con respecto a los mapas de clasificación y matrices de los datos de entrenamiento mostrados en las siguientes tablas.

Table 4: Redes con datos de entrenamiento

Configuración	Accuracy (%)
(20,20,20)	62.0
(35,35,35)	62.0
(33,40,33)	65.5

Table 5: Métricas para datos de entrenamiento

Configuración	Grupo	Presición (%)	Recall(%)	F1(%)
(20,20,20)	Alzheimer	60.0	80.0	69.0
(20,20,20)	Control	67.0	43.0	52.0
(35,35,35)	Alzheimer	60.0	80.0	69.0
(35,35,35)	Control	67.0	43.0	52.0
(33,40,34)	Alzheimer	63.0	80.0	71.0
(33,40,33)	Control	70.0	50.0	58.0

Se observa que de forma parecida a lo que sucedía con los datos de validación, se mantuvieron las matrices con valores similares, solamente mostrando variación con la última configuración de red.

La última configuración podría haberse sobreajustado a los datos de entrenamiento, lo que significa que el modelo aprendió específicamente los detalles y el ruido en esos datos. Esto podría haber llevado a diferencias en las métricas de rendimiento en los datos de entrenamiento, pero no en los datos de validación, que representan una evaluación más imparcial del rendimiento del modelo.

Las diferencias en la distribución de los datos de entrenamiento y validación pudieron haber afectado también el modelo. Si la última configuración es más sensible a ciertos patrones específicos en los datos de entrenamiento, podría haber cambios en las métricas de rendimiento en ese conjunto.

D. Aplicación de rutinas

D1 Kmeans

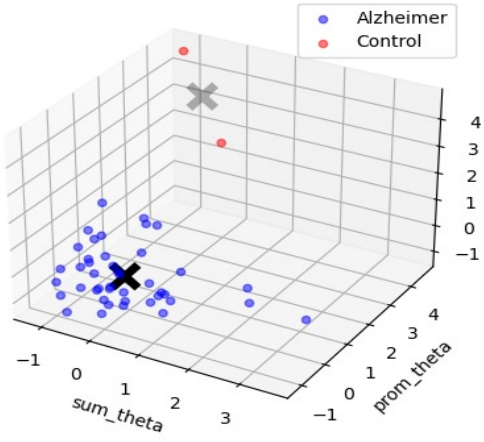

Fig. 18: distribución obtenida

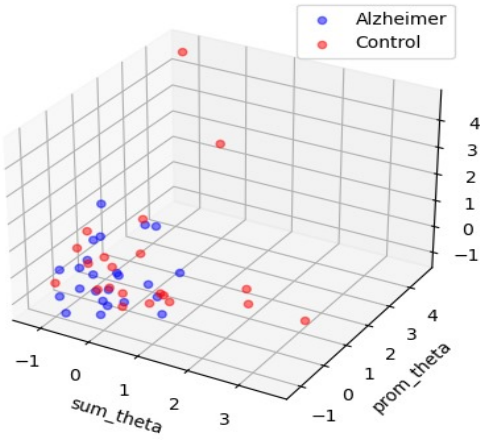

Fig. 19: distribución real

Como se mencionó anteriormente, lo que hace este modelo es agrupar observaciones similares para descubrir patrones, a estos patrones se les asigna un centroide y la idea es que pueda agrupar de forma correcta a los diferentes tipos de datos. En este caso, a los datos de dos grupos en especifico que son los de alzheimer y control, al parecer no los pudo agrupar correctamente al tal vez debido a la poca cantidad de datos.

Si se realiza una comparación con respecto a la distribución real de los datos en los grupos, se observa cómo fue de incorrecta la obtenida por el modelo.

La sensibilidad a la cantidad de datos y la dificultad para manejar grupos pequeños podrían estar contribuyendo a las dificultades observadas en la agrupación de los datos de control.

D2 Matriz de soporte vectorial

El objetivo de una SVM es encontrar el hiperplano óptimo que mejor separa dos clases en un espacio de características. Los puntos de datos más cercanos a este hiperplano son llamados ”vectores de soporte”. Los resultados de la matríz de soporte vectorial para este grupo de datos no fue muy positiva.

Se obtuvo un la siguiente configuración: SVC(C=2, kernel='sigmoid'.

El parámetro C , el cual en una máquina de soporte vectorial (SVM) controla la penalización por errores en la clasificación durante el entrenamiento del modelo. Es un hiperparámetro que se ajusta durante el proceso de entrenamiento para encontrar el equilibrio correcto entre lograr un límite de decisión más suave y clasificar correctamente los puntos de entrenamiento. En este caso, obtener un valor de C de dos quiere decir se está permitiendo una penalización moderada por los errores de clasificación.

Por otra parte, el parámetro kernel determina el tipo de kernel utilizado por el algoritmo SVM. En este caso, 'sigmoid' indica que se está utilizando un kernel sigmoidal. Este tiene la forma de la función de activación sigmoidal y se utiliza para mapear los datos en un espacio no lineal. Es decir, esa es la forma escogida para separar los datos.

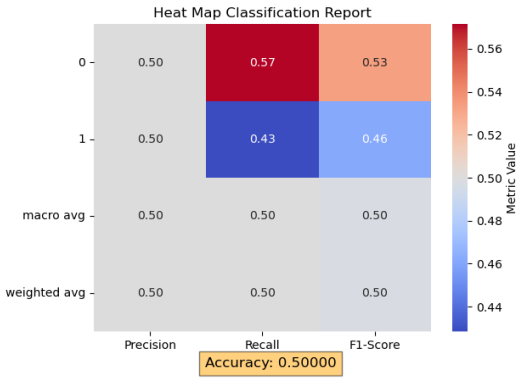

Fig. 20: Mapa de clasificación

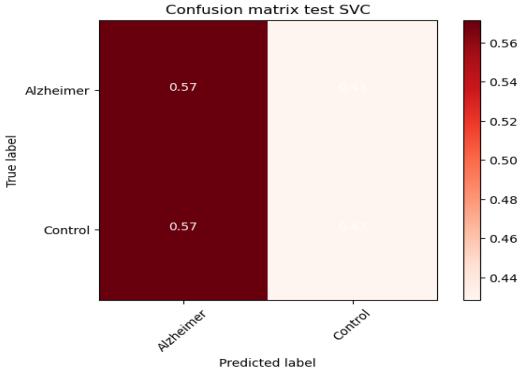

Fig. 21: Matríz de confusión

Finalmente se calcula la matríz de confusión y el mapa de clasificación correspondiente que muestra que se obtuvo un accuracy del 50%, el cual no es muy positivo.

Con respecto a la evaluación de las métricas, tanto la presición como el recall y el F1 score oscilaron entre valores del 50% o menores. Además de esto, se observa que en la matríz de confusión, se obtuvieron valores de 0,57 y o,43 con respecto a la identificación de valores correctos reales y valores negativos reales.

Esto muestra que tipo de modelo no es muy efectivo para este tipo de datos en especifico o, se necesitarían probar con

otro grupo de datos o incluso uno más grande para ver si mejora su comportamiento.

D3 Extreme gradient boost

Se obtuvo como mejor configuración la siguiente :

GradientBoosting Classifier(learning rate=0.01, max depth=4, n estimators=50)

Donde:

N estimators: Número de árboles en el ensamblado. Learning rate: Tasa de aprendizaje que controla la contribución de cada árbol. Max depth: Profundidad máxima de cada árbol.

Esto índica que se ésta utilizando un clasificador de aumento de gradiente con una tasa de aprendizaje baja, árboles relativamente poco profundos (con una profundidad máxima de 4), y 50 árboles en el ensamble.

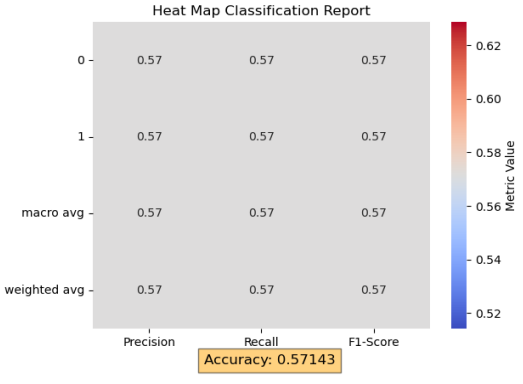

Fig. 22: Mapa de clasificación

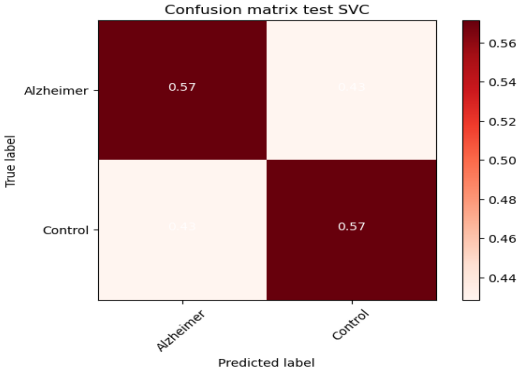

Fig. 23: Matríz de confusión

Con respecto al comportamiento de éste modelo con el conjunto de datos empleados, se observó que su accuracy fue de 57%. Mostrando también este mismo porcentaje en las métricas evaluadas, y también en la identificación de falsos positivos, falsos negativos, verdaderos positivos y verdaderos negativos.

Aunque no es un porcentaje bajo,es un porcentaje que está muy cercano al 50%, el modelo podría ajustarse mejor si el grupo de datos fuera más grane o quizás si se prueban más variaciones en su estructura.

VI. Conclusiones

En el análisis de las redes neuronales, se observó que, a pesar de variar la arquitectura de la red, los resultados de métricas como precisión, recall y f1-score se mantuvieron consistentes entre las configuraciones. Aunque se obtuvieron porcentajes de precisión superiores al 62%, indicando un entrenamiento positivo, la semejanza en los resultados sugiere que la arquitectura de la red no tuvo un impacto significativo en las métricas evaluadas. Sin embargo, las matrices de confusión revelaron una capacidad adecuada para identificar valores positivos y negativos en los datos.

En el contexto de las Máquinas de Soporte Vectorial (SVM), se experimentó con un clasificador utilizando un kernel sigmoidal y un parámetro de penalización (C) igual a 2. Se observaron desafíos en la clasificación del grupo de control, lo que podría atribuirse a la cantidad limitada de datos en ese grupo. La sensibilidad de la SVM a conjuntos de datos desbalanceados podría haber afectado su capacidad para establecer un límite de decisión eficaz.

En contraste, el modelo de Aumento de Gradiente (Gradient Boosting) fue afinado con éxito con una tasa de aprendizaje baja (0.01), árboles poco profundos (max depth=4) y 50 árboles en el ensamble. Estos valores resultaron ser óptimos en comparación con una búsqueda más amplia de hiperparámetros, destacando la importancia de ajustar cuidadosamente los parámetros para el rendimiento del modelo. Este hallazgo sugiere que, para este conjunto de datos específico, una tasa de aprendizaje baja y árboles poco profundos fueron más efectivos.

En relación con K-means, se observó que el algoritmo puede no agrupar de manera efectiva los datos de control debido a la poca cantidad de muestras en ese grupo. La sensibilidad de K-means a conjuntos de datos desbalanceados puede resultar en la asignación incorrecta de centroides, especialmente cuando hay grupos minoritarios.

En conclusión, el aprendizaje automático es un campo dinámico donde la adaptabilidad y la exploración constante de técnicas y modelos son fundamentales. La selección de algoritmos y parámetros adecuados debe basarse en una comprensión profunda del dominio del problema y la naturaleza de los datos. La experimentación continua, la validación rigurosa y el ajuste personalizado son prácticas

clave para lograr modelos efectivos y generalizables en diversas tareas de machine learning y redes neuronales.

REFERENCES

1. Brown Sara. Aprendizaje automático 2022. Accessed Nov. 26, 2023.
2. Campillo Samuel, Castells Francisco. Metodología Robusta Basada en los Fundamentos del Machine Learning Para la Clasificación de Señales Biomédicas. Aplicación a 3 Desafíos de la Ingeniería Biomédica Moderna 2022. Accessed Nov. 26, 2023.
3. Sanz F.. Algoritmo K-Means Clustering – aplicaciones y desventajas 2023. Accessed Nov. 26, 2023.
4. Introducción a las máquinas de vectores de soporte (SVM)
5. XGBoost 2023. Accessed Nov. 26, 2023.
6. Tamaño del efecto: qué es y por qué es importante 2022. Accessed Nov. 26, 2023.
7. Rowden A.. Frecuencia respiratoria normal según la edad 2019. Accessed Nov. 26, 2023.
8. Matemática y Estadística ¿Qué es una Matriz de Correlación? 2020. Accessed Nov. 26, 2023.
9. Marinescu Dan C., Marinescu Gabriela M.. *Classical and Quantum Information*. Academic Press 2012.